

Clasificación Automática de Emociones en Publicaciones de Jóvenes Peruanos mediante Técnicas de Minería de Datos

Cisneros Culaca, David
Escuela de Ingeniería de Software
Universidad Nacional Mayor de San Marcos
Lima, Perú
david.cisneros1@unmsm.edu.pe

Chavez Gave, Jose
Escuela de Ingeniería de Software
Universidad Nacional Mayor de San Marcos
Lima, Perú
jose.chavez40@unmsm.edu.pe

Tataje Guzman, Kenner
Escuela de Ingeniería de Software
Universidad Nacional Mayor de San Marcos
Lima, Perú
kenner.tataje@unmsm.edu.pe

Rojas Rojas, Jostein
Escuela de Ingeniería de Software
Universidad Nacional Mayor de San Marcos
Lima, Perú
darwin.rojas@unmsm.edu.pe

Patricio Julca, Vilberto
Escuela de Ingeniería de Software
Universidad Nacional Mayor de San Marcos
Lima, Perú
vilberto.patricio@unmsm.edu.pe

Keywords—*emotion detection, data mining, social network*

I. INTRODUCCIÓN

Las redes sociales se han convertido en un medio de comunicación donde los jóvenes peruanos pueden expresar sus emociones y sentimiento de manera inmediata. Al eliminar estas las barreras geográficas estas plataformas han logrado facilitar la interacción de los jóvenes logrando insertarse en su vida cotidiana. En consecuencia, se han generado grandes volúmenes de datos sobre la interacciones y comportamiento de los usuarios, siendo estos una gran fuente para el análisis mediante diferentes técnicas de minería de datos que nos permitirá poder identificar comportamientos y tendencias para así comprender las emociones que los jóvenes presentan o manifiestan dentro del entorno digital. Según las investigaciones de Paul Ekman [1], en la cual se identificó emociones básicas como la alegría, tristeza, miedo, ira, sorpresa y asco, las cuales constituyen respuestas universales que pueden identificarse mediante diferentes formas de expresión humana, siendo el enfoque principal de este proyecto el análisis de estas emociones que fueron propuestas por Paul Ekman.

A nivel nacional, la adopción de estas plataformas digitales mantiene un crecimiento sostenido. Según el reporte Digital 2025: Perú de DataReportal, Perú contaba al inicio de 2025 con 24,5 millones de usuarios activos con redes sociales lo que equivale a 71,2% de la población total, además de un total de 39,4 millones de conexiones móviles consolidando a estos canales como los medios principales de comunicación [2]. Esta tendencia es respaldada por el Instituto Nacional de Estadística e Informática (INEI) [3] que reporta que el 95,4% de los jóvenes entre 19 a 24 años accede a internet principalmente por el celular, lo que convierte a las plataformas digitales en el canal cotidiano de comunicación de este sector y genera un volumen masivo de publicaciones textuales sin procesar sobre las emociones de este sector de la población. Ante este escenario, la necesidad de procesar computacionalmente estos datos se vuelve prioridad, al contrastarse con los indicadores de salud del Ministerio de Salud (MINSA), el cual advierte que los jóvenes entre 18 y 29 años concentran el mayor número de atenciones vinculadas a desbordes emocionales a nivel nacional [4]. De igual manera, INSM señala que una alta proporción de jóvenes adultos en el Perú presenta dificultades en la regulación de emociones, manifestando episodios de estrés que se exteriorizan en publicaciones digitales [5].

A pesar de esta necesidad, el procesamiento automático del lenguaje natural (NPL) enfrenta desafíos técnicos estructurales en el contexto peruano, puesto que los sistemas predictivos y arquitecturas profundas suelen entrenarse con corpus en inglés o español formal, ignorando los textos informales. Estos últimos, siendo textos que contemplan jergas juveniles, expresiones o fenómenos como el sarcasmo que ocasiona una degradación analítica al aplicarse al español informal [6]. Por lo tanto, se evidencia la ausencia crítica de modelos de clasificación entrenados y validados que permita identificar y clasificar automáticamente emociones sobre publicaciones digitales escritos por los jóvenes peruanos en español informal.

En [7] se desarrolló un sistema automatizado de textos denominado EmoNet orientada a clasificar microtextos en redes sociales como X. El sistema integra el módulo AttentionEmbedder para calcular representaciones léxicas ponderadas, luego son

procesadas en paralelo por capas para la extracción de características secuenciales temporales, alcanzando una precisión de 95.51%, el sistema presenta una elevada complejidad computacional y fue entrenado con datos que no consideran el sarcasmo o el cambio de código idiomático, evidenciando una necesidad de nuevas propuestas capaces de adaptar estos sistemas híbridos multivariantes al procesamiento de jergas locales, modismos y variaciones lingüísticas propias del contexto de los jóvenes en el Perú, factores que el modelo estandarizado actual no logra capturar con total precisión.

El estudio de Adebajji et al. [8] aborda el problema de la detección tardía de la depresión en plataformas digitales. La investigación busca evaluar el impacto del pre-entrenamiento y ajustar modelos lingüísticos para identificar rasgos depresivos en textos extraídos de redes sociales. Las técnicas aplicadas abarcaron representaciones como Bag of Words y embeddings (Word2Vec/Glove) combinadas con clasificadores tradicionales, contrastándolas con modelos avanzados de aprendizaje profundo como BERT, RoBERTa y ELECTRA. A pesar de que las arquitecturas basadas en Transformers lograron un rendimiento sobresaliente con un F1 score de hasta 0.99, el problema que aún existe es que estos modelos fueron entrenados y evaluados exclusivamente en un corpus de idioma inglés. Esto genera la necesidad de nuevas propuestas metodológicas que adapten y validen estas técnicas predictivas en el contexto hispanohablante regional, donde el uso de modismos locales y jergas introducen un ruido lingüístico que los modelos tradicionales no logran interpretar eficazmente.

Por otro lado, investigaciones como la de Matsumoto et al. [9] se diseñó un modelo en donde se integra la vectorización inicial mediante arquitecturas ligeras de Transformers como DistilBERT, acoplándolas a redes neuronales profundas con funciones de activación Mish, diseñadas para retener valores vectoriales negativos, y capas de salida con funciones Sigmoide. Este pipeline permitió realizar tareas multi-aprendizaje supervisado bajo la taxonomía de Fisher (25 clases afectivas) para extraer vectores ocultos emocionales (E-HV) de 128 dimensiones y vectores ocultos semánticos (S-HV) de 103 dimensiones. No obstante, la necesidad de nuevas propuestas de investigación radica en que el modelo fundamenta su entrenamiento en diccionarios formales y corpus literarios estructurados de la web, mostrando una degradación en su eficiencia analítica al enfrentarse a expresiones coloquiales caóticas, fragmentadas y altamente dinámicas propias de las interacciones orgánicas en redes sociales actuales. Esto justifica el desarrollo de nuevos enfoques de minería orientados al procesamiento de comentarios del ecosistema social real, adaptando los diccionarios de sentimientos hacia los modismos y jergas específicos de las comunidades digitales de nuestra región.

En la investigación [10], se aborda la limitación de los métodos tradicionales de clasificación de una sola etiqueta, los cuales son insuficientes para la captura de múltiples emociones en los textos de las redes sociales. Los autores proponen una solución, desarrollar un modelo de clasificación multi-etiqueta mejorado para realizar el análisis de emociones en tweets. Las técnicas empleadas por los autores, implica el uso de un modelo de aprendizaje profundo basado en la arquitectura de Transformers, utilizando la versión de RoBERTa preentrenada para tweets (TweetNLP). Para mejorar el análisis de emociones, los autores integran un mecanismo llamado autoatención de múltiples cabezales, este enfoque procesa el texto en paralelo para que diferentes cabezales identifiquen relaciones y dependencias entre distintas palabras, ya sea relaciones de tiempo, tono, etc. Posteriormente, combina el modelo con redes neuronales densas para transformar la representación de los datos y extraer las características más relevantes. Finalmente, se aplica una técnica matemática de evaluación (BCEWithLogitsLoss) para evaluar de manera independiente la probabilidad de cada categoría emocional, facilitando la detección de un conjunto de emociones en un mismo mensaje.

En la investigación [11] se describe el diseño y construcción de una plataforma educativa inteligente basada en analítica de big data (Apache Kafka y clústeres de Hadoop), orientada a resolver la falta de interactividad y flexibilidad semántica de los modelos de enseñanza tradicionales, los cuales no logran adaptarse a la variabilidad del comportamiento ni a la respuesta emocional del estudiante con el objetivo de mapear respuestas afectivas mediante modelos basados en grafos. El programa implementó un clasificador basado en BERT para detectar la polaridad del sentimiento (positivo, neutral o negativo) a través de entradas multimodales como reflexiones escritas e interacciones en clase. A pesar de que la plataforma alcanzó una precisión del 92% en relevancia de contenido y una sensibilidad del 88% en el alineamiento de sentimientos, el análisis identifica una necesidad crítica de mejorar la inferencia causal para distinguir entre el aprendizaje intencional y la exposición accidental, además de requerir métodos de autocuración frente a ruidos adversarios en contextos de ejecución móvil.

El objetivo de la presente investigación es diseñar y evaluar un modelo de minería de textos para la clasificación automática de 5 emociones, principalmente en publicaciones de redes sociales enfocada en los jóvenes peruanos, utilizando técnicas de aprendizaje automático.

Este proyecto se justifica por la necesidad real de entender cómo se sienten los jóvenes peruanos a partir de los comentarios y publicaciones en redes sociales. Ya que, las redes sociales son el espacio donde más comparten su día a día y donde se genera una gran cantidad de información, lo que resulta difícil de analizar manualmente toda esa información o de donde muchas de las herramientas actuales fallan porque no están preparadas para entender nuestro español coloquial mezclado con las jergas locales. Por eso, la relevancia de desarrollar un modelo de minería de texto enfocado en identificar las emociones que los

jóvenes peruanos expresan en sus mensajes es fundamental, ya que podría contribuir en una mejor comprensión de su bienestar emocional y la detección temprana de posibles problemas.

II. TRABAJOS RELACIONADOS

La clasificación de emociones en texto se ha abordado desde 3 enfoques complementarios dentro de la minería de datos y el procesamiento de lenguaje natural (PLN): aprendizaje automático, deep learning y Transformers. El aprendizaje automático emplea algoritmos supervisados que identifican patrones emocionales a partir de representaciones textuales. El deep learning utiliza redes neuronales capaces de aprender por sí misma características complejas del lenguaje. Transformers aprovecha mecanismos de atención para llegar a comprender mejor el contexto y las relaciones que existen entre las palabras dentro de los textos. En conjunto, estas tres líneas constituyen el marco teórico del presente proyecto enfocado en la clasificación de emociones en publicaciones de jóvenes peruanos. A continuación, se comparan las categorías en seis métricas seleccionadas.

A. Modelos y Arquitecturas

En aprendizaje automático utilizan clasificadores lineales como las Máquinas de Vectores de Soporte (SVM), Naive Bayes y los árboles de decisión los cuales destacan por su eficiencia computacional, su claridad interpretativa y la rápida generalización al procesar corpus estructurados y homogéneo [12], [13]. Por su parte, Machová et al [14]., señala que estos clasificadores lineales no tienen la capacidad paramétrica necesaria para llegar a comprender la ironía o conectar dependencias secuenciales a largo plazo en textos informales. Para manejar esta falta de comprensión, en deep learning introducen las redes neuronales jerárquicas (CNN y LSTM) e híbridas (DAR-CNN) que pueden extraer automáticamente patrones léxicos y temporales directos del texto, superando ampliamente la precisión de los métodos convencionales al analizar micro textos altamente ruidosos [7], [15], [16], [17]. En Transformers (BERT, RoBERTa) sus arquitecturas usan complejos mecanismos de autoatención bidireccional y selección dinámica de ensambles (DES) que son capaces de lograr desambiguar emociones solapadas, siendo un aspecto imposible para las redes recurrentes [8], [18]. A pesar de su efectividad, estos requieren de una gran cantidad de recursos y llegan a sufrir caídas de rendimiento ante modismos regionales, lo que ha llevado a impulsar la investigación actual a priorizar variantes lingüísticas preentrenadas y ajustadas al dominio específico (como SaBERT o BERTurk) para poder neutralizar el fuerte sesgo dialectal que penaliza a los modelos globales [19], [20].

B. Técnicas y Algoritmos de Minería de Datos

El aprendizaje automático utiliza representaciones vectoriales como Bag of Words (BoW) y N-gramas, junto con técnicas de preprocesamiento como stemming y eliminación de stopwords para facilitar la clasificación de emociones y sentimientos [12], [13], [21]. Dichas técnicas ofreciendo buenos resultados en tareas básicas, aunque con limitaciones para comprender contexto y significado de palabras. En deep learning representan las palabras mediante embeddings, permitiendo capturar mejor las relaciones semánticas dentro del texto. Algunas investigaciones emplean técnicas como SMOTE reduciendo el problema del desbalance de clases y mejorando el desempeño de los modelos [15], [22]. También se utilizan recursos como NRCLexicon y operaciones de Global Max Pooling para identificar características emocionales relevantes en los textos [7], [16]. En Transformers, el proceso se centra principalmente en el fine-tuning de modelos previamente entrenados. Estas arquitecturas utilizan mecanismos de atención multi-cabezal que analizan diferentes relaciones entre las palabras y pueden emplear funciones de pérdida como BCEWithLogitsLoss en tareas de clasificación multietiqueta [10], [18], [23]. Asimismo, algunas investigaciones incorporan modelos psicológicos como la taxonomía de Ekman para organizar la clasificación de emociones en categorías definidas [20].

C. Conjuntos de Datos y Recursos Empleados

Los tipos de datos que se eligen para entrenar los modelos definen qué tan bien van a funcionar en situaciones reales. Existe una fuerte tendencia a validar las propuestas utilizando grandes repositorios públicos con corpus en inglés extraídos de redes sociales populares como Reddit o X [14], [18], [24], [25], [26]. El problema de usar estas bases de datos globales es que suelen dejar de lado las particularidades de otros idiomas. Frente a la falta de datos en lenguas menos comerciales, varias investigaciones optaron por construir conjuntos de datos propios con un enfoque dialectal o regional específico [9], [26], [27], [28] permitiendo capturar de manera más fidedigna lo que las personas expresan en el día a día. Por otro lado, si se enfrenta a problemas de mayor complejidad o eventos a gran escala, la recolección de datos cambia hacia macro-corpus lingüísticos enfocados en la geografía emocional y clasificación multietiqueta [10], [12], [15], [21], [24], [29]. Procesando millones de palabras geotiquetadas, con el objetivo de ver la variación del ánimo de una población en tiempo real. Investigaciones más recientes han explorado entornos multimedia, recopilando videos de plataformas abiertas como YouTube para obtener y armar datasets que combinan transcripciones de texto con las expresiones del rostro humano y cambios en el tono de voz [7], [8], [9], [21], [24].

D. Resultados y Métricas de Evaluación

Se notó que el éxito de los clasificadores depende de qué tan balanceada esté la muestra y de las estrategias matemáticas que reduzcan las tasas de errores. Los modelos tradicionales muestran niveles de precisión aceptables, entre el 81% y el 89% cuando se aplican algoritmos de balanceo como SMOTE o herramientas de evaluación masiva [9], [12], [21], [23], [27]. Mientras que las arquitecturas que utilizan redes híbridas más profundas y optimizadores logran obtener valores cercanos al 93% y 98%, al clasificar la gravedad de un estado de ánimo en varios niveles discretos [15], [28], [30], [31]. El rendimiento de

los Transformers y modelos de transferencia, dependen de la complejidad y naturaleza del corpus. Los modelos que detectan múltiples en un mismo texto o diálogo complejo suelen optimizar el margen de error, con un F1-score de aproximadamente 75% [15], [18], [25]. Pero si se combinan con redes neuronales y grafos de conocimiento, la precisión puede llegar hasta rangos entre 91% y 96% en textos desestructurados [7], [9], [14], [26], [31], [32].

Las propuestas ajustadas para idiomas específicos mediante embeddings en español (BETO o SaBERT) se mostraron superiores frente a clasificadores tradicionales [28], [30]. En entornos de big data, el uso de pipelines de transferencia de conocimiento sobre Apache Spark alcanzó multi-accuracies del 78.71% y F1-macros del 78.55% [24], [26], [29], [33], [34]. Mientras que, en los entornos de aprendizaje continuo incremental, los algoritmos de regularización como EWC mantuvieron el F1-score por encima del 91.00% [13], [23].

E. Metodologías de Evaluación y Validación

En PLN, las metodologías enfocadas en el aprendizaje automático emplean métodos de evaluación (Accuracy, Precisión y F1-score), evaluadas mediante validación cruzada de 10 pliegues con GridSearchCV [12], [14], [21], [22]. Por otro lado, el Deep Learning tiene como privilegio el F1-score macro y ROC-AUC se enfoca en datasets desbalanceados, que incorpora la tasa de olvido catastrófico como una métrica de estabilidad, además el aprendizaje es incremental con regulación EWC [8],[15], [30], [33]. Finalmente, los Transformers pueden adoptar F1 en sus diferentes variantes (micro, macro y Hamming Loss) en tareas de multi-etiqueta sobre los benchmarks estandarizados, lo que permiten hacer una comparación más directa entre los diversos modelos [7], [18], [32]. Por lo que, estas metodologías reflejan que existe una complejidad real en poder realizar una evaluación de emociones, donde la selección de métricas y los protocolos de validación no ocurre de manera arbitraria, sino surge directamente al tipo de arquitectura que se plantea y también al grado de desbalance del dataset.

F. Preprocesamiento y Manejo de Ruido Textual

En el aprendizaje automático se aplica diferentes técnicas léxica como la eliminación de stopwords, lematización y también se puede aplicar el filtrado de términos raros (min_df=5) y muy en ocasiones muy frecuentes (max_df=0.9) [24], además podemos combinar filtros sintácticos PosTag y Chunking sobre representación BoW [13], [22]. Por otro lado, el Deep Learning incorpora embedding que son densos como Word2Vec, GloVe y FastText que se adapta al lenguaje de Código mixto, reduciendo el impacto del ruido principalmente en los textos informales, lo que significa que alcanza mejoras sustanciales frente a arquitectura que no tuvieron preprocesamiento semántico [8], [15], [33]. Para finalizar, los Transformers gestionan el ruido mediante tokenización contextual propia de BERT y RoBERTa, también con el remuestreo sintético SMOTE frente a variaciones dialectales y estrategias de enmascaramiento de roles para que se utilicen en conversaciones con textos ambiguos, logrando así superar a enfoques que no contiene estrategias [18], [26], [32]. Estas metodologías se permiten resolver la complejidad del procesamiento textual, reduciendo así el ruido textual y el lenguaje, lo que se traduce en que el modelo puede capturar de una mejor manera las señales emocionales presentes en los textos.

III. REFERENCIAS

- [1] P. Ekman y D. Cordaro, “What is Meant by Calling Emotions Basic”, *Emot. Rev.*, vol. 3, núm. 4, pp. 364–370, oct. 2011, doi: 10.1177/1754073911410740.
- [2] “Digital 2025: Peru”, DataReportal – Global Digital Insights. Consultado: el 5 de junio de 2026. [En línea]. Disponible en: <https://datareportal.com/reports/digital-2025-peru>
- [3] “Instituto Nacional de Estadística e Informática”. Consultado: el 5 de junio de 2026. [En línea]. Disponible en: <https://m.inei.gob.pe/prensa/noticias/aumento-la-poblacion-usuaria-de-internet-en-todos-los-grupos-de-edad-en-el-primer-trimestre-de-2024-15248/>
- [4] “Minsa: jóvenes entre 18 y 29 años realizan mayor número de consultas por salud mental a través de la Línea 113”. Consultado: el 5 de junio de 2026. [En línea]. Disponible en: <https://www.gob.pe/institucion/minsa/noticias/1227865>
- [5] J. E. S. Castillo *et al.*, “Estudio Epidemiológico de Salud Mental en Lima Metropolitana y Callao - Replicación 2012: Publicado: 14 de enero de 2014”, *An. Salud Ment.*, vol. 29, núm. Suplemento 1, p. 1-397, 2013.
- [6] F. M. Plaza-del-Arco, M. T. Martín-Valdivia, L. A. Ureña-López, y R. Mitkov, “Improved emotion recognition in Spanish social media through incorporation of lexical knowledge”, *Future Gener. Comput. Syst.*, vol. 110, pp. 1000–1008, sep. 2020, doi: 10.1016/j.future.2019.09.034.
- [7] Md. S. Hossain, Md. M. Hossain, Md. S. Hossain, M. F. Mridha, M. Safran, y S. Alfarhood, “EmoNet: Deep Attentional Recurrent CNN for X (Formerly Twitter) Emotion Classification”, *IEEE Access*, vol. 13, pp. 37591–37610, 2025, doi: 10.1109/ACCESS.2025.3545863.
- [8] O. O. Adebajji *et al.*, “Adaptation of Transformer-Based Models for Depression Detection”, *Comput. Syst.*, vol. 28, núm. 1, pp. 151–165, mar. 2024, doi: 10.13053/cys-28-1-4691.
- [9] K. Matsumoto *et al.*, “Emotional Similarity Word Embedding Model for Sentiment Analysis”, *Comput. Syst.*, vol. 26, núm. 2, pp. 875–886, jun. 2022, doi: 10.13053/cys-26-2-4266.

- [10] P. Anthony y J. Zhou, “Leveraging Transformer with Self-Attention for Multi-Label Emotion Classification in Crisis Tweets”, *Informatics*, vol. 12, núm. 4, p. 114, dic. 2025, doi: 10.3390/informatics12040114.
- [11] P. Xu, Q. Lu, R. Wang, y S. Yang, “Construction of a Smart Educational Platform for Red Culture Based on Big Data Analytics”, en *Proc. Int. Conf. Mach. Intell. Digit. Appl., MIDA*, Association for Computing Machinery, Inc, 2025, pp. 121–127. doi: 10.1145/3744464.3744484.
- [12] S. Chaffar y D. Inkpen, “Using a Heterogeneous Dataset for Emotion Analysis in Text”, may 2011, pp. 62–67. doi: 10.1007/978-3-642-21043-3_8.
- [13] H. Fernando, “Estudo sobre análise de sentimentos em textos”, masterThesis, Universidade de Évora, 2013. Consultado: el 2 de junio de 2026. [En línea]. Disponible en: <https://www.rdp.uevora.pt/handle/10174/18267>
- [14] K. Machová, M. Szabóová, J. Paralič, y J. Mičko, “Detection of emotion by text analysis using machine learning”, *Front. Psychol.*, vol. 14, p. 1190326, sep. 2023, doi: 10.3389/fpsyg.2023.1190326.
- [15] S. Ansari, A. Shaikh, U. Khairdi, y M. Kazi, “Emotion Detection from Text using CNN, LSTM and Hybrid CNN-LSTM Deep Learning Model”, *Int. J. Sci. Res.*, vol. 12, núm. 2, 2026.
- [16] R. Olusegun, T. Oladunni, H. Audu, Y. Houkpati, y S. Bengesi, “Text Mining and Emotion Classification on Monkeypox Twitter Dataset: A Deep Learning-Natural Language Processing (NLP) Approach”, *IEEE Access*, vol. 11, pp. 49882–49894, 2023, doi: 10.1109/ACCESS.2023.3277868.
- [17] M. Kastrati, Z. Kastrati, A. S. Imran, y M. Biba, “Leveraging Distant Supervision and Deep Learning for Twitter Sentiment and Emotion Classification”, *J. Intell. Inf. Syst.*, vol. 62, pp. 1045–1070, mar. 2024, doi: 10.1007/s10844-024-00845-0.
- [18] F. H. Labib, M. Elagamy, y S. N. Saleh, “EmoBERTa-X: Advanced Emotion Classifier with Multi-Head Attention and DES for Multilabel Emotion Classification”, *Big Data Cogn. Comput.*, vol. 9, núm. 2, p. 48, feb. 2025, doi: 10.3390/bdcc9020048.
- [19] Y. Mamani-Coaquira, M. J. Ibarra-Cabrera, M. Aquino-Cruz, y W. J. Mollocondo-Flores, “ApuEmo: Emotion Classification in Spanish Through a Hybrid Model With Transformer and Recurrent Layer”, *IEEE Access*, vol. 13, pp. 186014–186029, 2025, doi: 10.1109/ACCESS.2025.3623629.
- [20] M. Toğaçar *et al.*, “Transformer-Based Emotion and Conflict Analysis of Disaster-Related Social Media: An Actor-Aware Decision Support Framework”, *Appl. Sci.*, vol. 16, núm. 8, p. 3877, ene. 2026, doi: 10.3390/app16083877.
- [21] H. H. Al-Baity *et al.*, “Computational Linguistics Based Emotion Detection and Classification Model on Social Networking Data”, *Appl. Sci.*, vol. 12, núm. 19, p. 9680, ene. 2022, doi: 10.3390/app12199680.
- [22] M. M. Rahman y S. Sharmin, “Emotion Detection From Social Media Posts”, 2023, *arXiv*. doi: 10.48550/ARXIV.2302.05610.
- [23] H. Rodríguez-Arteaga *et al.*, “Architecture of a Socio-Emotional Conversational Agent Capable of Identifying Intentions within a Socratic Dialogue”, *Comput. Syst.*, vol. 28, núm. 3, pp. 1679–1685, sep. 2024, doi: 10.13053/cys-28-3-5167.
- [24] A. Ocal, “A Computational Analysis of Emotions and Topics in YouTube Discourse on Sora”, *Appl. Sci.*, vol. 16, núm. 5, p. 2519, ene. 2026, doi: 10.3390/app16052519.
- [25] M. Subramanian, G. Deepalakshmi, K. Shanmugavadivel, U. Moorthy, y S. V. Easwaramoorthy, “Preventing Catastrophic Forgetting in New Tasks: Development of Artificial Intelligence Based Models for Depression Detection in Continual Learning Settings”, *Int. J. Comput. Intell. Syst.*, vol. 19, núm. 1, 2026, doi: 10.1007/s44196-026-01278-z.
- [26] N. Abdelhady, I. E. Elsemman, y T. H. A. Soliman, “A Real-Time Predicting Online Tool for Detection of People’s Emotions From Arabic Tweets Based on Big Data Platforms”, *J. Big Data*, vol. 11, nov. 2024, doi: 10.1186/s40537-024-01035-z.
- [27] A. Patnukao, “Emotional geography in the digital age: a Twitter-based study of population well-being in Thailand during COVID-19”, *Humanit. Soc. Sci. Commun.*, vol. 13, núm. 1, 2026, doi: 10.1057/s41599-026-06867-z.
- [28] H. Alkasem, A. Alsalamah, L. Alhussan, N. Alzahrani, y S. Aba-alkhail, “Machine learning methods for detecting depression in Arabic tweets: a comprehensive performance analysis with enhanced evaluation metrics”, *Discov. Artif. Intell.*, vol. 6, núm. 1, 2026, doi: 10.1007/s44163-026-00842-y.
- [29] T. Chutia y N. Baruah, “A review on emotion detection by using deep learning techniques”, *Artif. Intell. Rev.*, vol. 57, jul. 2024, doi: 10.1007/s10462-024-10831-1.
- [30] B. Kalingwar *et al.*, “Emotion Detection Face from Social Media Text Using CNN-LSTM Hybrid Model”, vol. 13, núm. 3, 2026.
- [31] M. Kayal, J. Pati, y S. Kumar, “IBNN: an integrated BERT-neural network framework for sentiment and emotion based text analysis”, *Sci. Rep.*, may 2026, doi: 10.1038/s41598-026-49099-6.
- [32] M. Abulaish y A. Bhardwaj, “RoEmo: A Role-Aware Commonsense-Augmented Contrastive Learning Framework for Emotion Classification”, *Mach. Learn. Knowl. Extr.*, vol. 8, núm. 3, p. 79, mar. 2026, doi: 10.3390/make8030079.
- [33] V. J. Ramya y Y. M. Manu, “A hybrid explainable machine learning and transformer-based framework for psychological stress detection in women’s social media narratives”, *Discov. Artif. Intell.*, vol. 6, núm. 1, 2026, doi: 10.1007/s44163-026-01055-z.
- [34] G. Gamage, D. De Silva, N. Mills, D. Alahakoon, y M. Manic, “Emotion AWARE: An Artificial Intelligence Framework for Adaptable, Robust, Explainable, and Multi-Granular Emotion Analysis”, *J. Big Data*, vol. 11, jul. 2024, doi: 10.1186/s40537-024-00953-2.

